



Data Science: Journal Of Computing And Applied Informatics

Journal homepage: <https://jocai.usu.ac.id>



Big Data Pipeline for E-Commerce Analytics Using Apache Spark, MySQL, and MongoDB

Esticka Priscila Sibarani^{*1} , Anisetus Bambang Manalu² , Wahyudi G. Lumbantoruan³ , Gabriel Dominggo A. Siregar⁴ , Nicolas Prasetya H. Batubara⁵

^{1,2,3,4,5}Institut Teknologi Del, Laguboti, North Sumatra 22381, Indonesia

*Corresponding Author: gabrielsiregar758@gmail.com, estickas@gmail.com

ARTICLE INFO

Article history:

E-ISSN:

P-ISSN:

How to cite:

Priyanka M. Sahu and Prof. D. M. Sable, "A Survey Paper on Targeted Advertising using Location – Based Behavioural Data and Social Data," International Journal of Engineering Research and, vol. V5, no. 11, Nov. 2016, doi: 10.17577/ijertv5is110238.

ABSTRACT

Pipeline big data telah menjadi kebutuhan kritis untuk platform e-commerce mengelola volume transaksi yang sangat besar. Penelitian ini mengembangkan sistem big data terintegrasi end-to-end yang memproses 128.975 catatan penjualan Amazon menggunakan Apache Spark sebagai mesin pemrosesan terdistribusi, MySQL untuk penyimpanan data relasional, dan MongoDB untuk analitik berorientasi dokumen. Tahap pembersihan data menghapus 15.971 catatan tidak valid sambil mempertahankan integritas informasi, menghasilkan dataset bersih 113.004 transaksi di 9 kategori produk selama periode Maret-Juni 2022. Proses pembersihan menangani 6.872 nilai null pada courier_status, 7.795 null pada amount dan currency, serta melakukan normalisasi data kategori. Sistem mengimplementasikan 8 query SQL analitik menggunakan Spark SQL untuk mengekstrak insight penting termasuk performa kategori produk, tren penjualan bulanan, distribusi status order, dan analisis dampak promosi. Integrasi MySQL dan MongoDB memungkinkan penyimpanan dan analisis data dilakukan secara konsisten pada sistem relasional maupun dokumen. Hasil menunjukkan tingkat keberhasilan pengiriman 90,4%, nilai order rata-rata Rp 627,49, dengan kategori Set mendominasi 50% pendapatan. Analisis temporal mengungkapkan puncak penjualan pada April dengan 39.071 pesanan kemudian penurunan musiman -13% di Juni. Geografis mengkonsentrasi pada 15 negara bagian teratas dengan 89,2% dari total penjualan. Pipeline ini menyediakan fondasi skalabel untuk monitoring, forecasting prediktif dan sistem business intelligence dalam lingkungan e-commerce volume tinggi.

Keyword: Big Data; E-Commerce Analytics; MongoDB; MySQL; PySpark; Sales Prediction

ABSTRAK

Analitik big data menjadi bagian penting dalam platform e-commerce untuk membantu memahami perilaku pelanggan dan meningkatkan efisiensi operasional. Penelitian ini membangun pipeline big data menggunakan Apache PySpark untuk pemrosesan data terdistribusi, MySQL sebagai penyimpanan data relasional dan MongoDB untuk analisis berbasis dokumen pada data penjualan Amazon periode Maret-Juni 2022. Sebanyak 128.975 data transaksi diproses melalui tahap pembersihan data sehingga 15.971 data yang tidak valid berhasil dihapus dan menghasilkan 113.004 data bersih. Tahap feature engineering menghasilkan enam atribut baru yang digunakan dalam proses analisis. Hasil penelitian menunjukkan tingkat keberhasilan pengiriman sebesar 90,4% dengan rata-rata nilai pesanan Rp627,49. Kategori produk set memberikan kontribusi terbesar terhadap pendapatan dengan persentase sekitar 50%. Analisis temporal menunjukkan jumlah transaksi tertinggi terjadi pada bulan April dengan 39.071 pesanan dan pendapatan Rp24,7 juta, kemudian mengalami penurunan pada bulan Juni. Selain itu, 15 wilayah teratas menyumbang 89,2% dari total penjualan.



This work is licensed under a Creative Commons Attribution-ShareAlike 4.0 International.

<http://doi.org/10.26594/register.v6i1.idarticle>

Integrasi MySQL dan MongoDB berhasil mendukung penyimpanan dan analisis data secara konsisten sehingga sistem dapat digunakan sebagai dasar pengembangan monitoring dan business intelligence pada lingkungan e-commerce berskala besar.

Keyword: Big Data; E-Commerce Analytics; MongoDB; MySQL; PySpark; Sales Prediction

1. Introduction

Perkembangan platform e-commerce yang semakin pesat menyebabkan jumlah data transaksi terus meningkat dari waktu ke waktu. Data tersebut dapat dimanfaatkan untuk membantu analisis bisnis, memahami perilaku pelanggan, dan mendukung proses pengambilan keputusan. Amazon sebagai salah satu platform e-commerce terbesar di dunia memproses jutaan transaksi setiap hari yang berasal dari berbagai kategori produk dan wilayah penjualan. Besarnya volume data tersebut membuat pengolahan menggunakan database relasional tradisional menjadi kurang efektif, terutama untuk proses analisis data dalam skala besar. Oleh karena itu, dibutuhkan teknologi pemrosesan data terdistribusi yang mampu mengolah data secara lebih cepat dan efisien[1].

Apache Spark merupakan salah satu framework yang banyak digunakan dalam pengolahan big data karena mendukung komputasi in-memory, memiliki toleransi kesalahan, dan mampu memproses data dalam jumlah besar[2]. Dengan menggunakan PySpark, proses pengolahan data dapat dilakukan dengan lebih efisien dibandingkan metode konvensional. Selain proses pengolahan data, media penyimpanan juga menjadi bagian penting dalam sistem big data. MySQL sebagai database relasional memiliki kemampuan dalam menjaga konsistensi transaksi dan mendukung query terstruktur, sedangkan MongoDB sebagai database NoSQL lebih fleksibel dalam menyimpan data berbasis dokumen dan semi-terstruktur.


Penelitian mengenai analisis penjualan e-commerce sebelumnya umumnya masih berfokus pada penggunaan satu jenis basis data atau hanya menitikberatkan pada visualisasi hasil analisis. Beberapa penelitian juga belum mengintegrasikan tahapan pengolahan data secara menyeluruh mulai dari preprocessing, analisis terdistribusi, hingga penyimpanan data pada arsitektur yang mendukung kebutuhan big data. Selain itu, penggunaan Apache Spark dan Spark SQL yang dikombinasikan dengan MySQL serta MongoDB dalam satu sistem analitik terpadu masih relatif terbatas pada penelitian berbasis transaksi e-commerce berskala besar. Berdasarkan kondisi tersebut, penelitian ini mengembangkan pipeline big data terintegrasi yang mencakup proses pembersihan data, pembentukan atribut baru, analisis menggunakan Spark SQL, serta implementasi penyimpanan hybrid berbasis relational database dan document database untuk mendukung analisis penjualan yang lebih fleksibel, terstruktur, dan scalable.

2. Metode

2.1 Data Collection

Dataset yang digunakan dalam penelitian ini berupa data laporan penjualan Amazon yang diperoleh dari Kaggle dengan jumlah 128.975 data transaksi dan 24 atribut awal[3]. Data mencakup transaksi penjualan selama periode Maret hingga Juni 2022 dari berbagai kategori produk seperti Set, Kurta, Western Dress, Top, Ethnic Dress, Blouse, Bottom, Saree, dan Dupatta yang tersebar di 46 wilayah di India. Beberapa atribut yang digunakan antara lain identitas pesanan (`order_id`), tanggal transaksi, kategori dan ukuran produk, SKU, ASIN, jenis pemenuhan pesanan, saluran penjualan, serta informasi pengiriman seperti kota, negara bagian, kode pos, dan negara tujuan pengiriman. Dataset ini memiliki struktur data yang cukup lengkap sehingga dapat digunakan dalam proses analisis penjualan, pengolahan big data, dan identifikasi pola perilaku pelanggan.


Gambar 1 menunjukkan alur utama penelitian yang dimulai dari pengumpulan dataset Amazon dari Kaggle, dilanjutkan dengan proses preprocessing menggunakan PySpark, pembentukan atribut baru melalui feature engineering, analisis menggunakan Spark SQL, serta penyimpanan data ke dalam MySQL dan MongoDB untuk mendukung analisis dan visualisasi data secara fleksibel.



Gambar 1. Architecture of the Proposed Big Data Analytics Pipeline

2.2 Data Preprocessing

Praproses data dilakukan untuk meningkatkan kualitas dataset sebelum tahap analisis. Dataset transaksi e-commerce umumnya masih mengandung data yang tidak lengkap, tidak konsisten, maupun data duplikat sehingga perlu dibersihkan terlebih dahulu agar hasil analisis menjadi lebih akurat[4]. Pada penelitian ini, tahapan pra proses meliputi penghapusan kolom yang tidak digunakan (row_index, unused_col), penanganan missing value (6.872 null courier_status diisi 'Unknown', 7.792 null amount/currency dihapus dan 33 null lokasi dihapus), normalisasi data kategori (konversi huruf besar pada city/state), konversi tipe data (string tanggal ke DateType), dan penghapusan data duplikat berdasarkan order_id (862 duplikat dihapus). Beberapa nilai yang hilang pada atribut tertentu ditangani menggunakan proses imputasi dan penghapusan data yang tidak valid. Selain itu, dilakukan penyesuaian format data pada atribut tanggal dan kategori untuk menjaga konsistensi data. Setelah proses pembersihan selesai, diperoleh 113.004 data yang siap digunakan untuk tahap analisis dan pengolahan lebih lanjut.



Gambar 2. Data Preprocessing Workflow

2.3 Feature Engineering and Derived Attributes

Pada tahap feature engineering, beberapa atribut baru dibuat dari data asli untuk mendukung proses analisis[5]. Atribut year, month, dan month_name diperoleh dari atribut date untuk membantu analisis temporal berdasarkan waktu transaksi. Selain itu, atribut status_group digunakan untuk mengelompokkan status pesanan ke dalam beberapa kategori utama seperti shipped, cancelled, pending, dan other agar proses analisis lebih sederhana. Atribut revenue dihitung berdasarkan hasil perkalian quantity dan amount untuk memperoleh total nilai transaksi pada setiap pesanan. Penelitian ini juga menambahkan atribut has_promotion untuk menunjukkan keberadaan kode promosi pada transaksi. Penambahan atribut turunan ini membantu proses analisis penjualan, tren transaksi, serta pengaruh promosi terhadap performa penjualan.

Tabel 1. Feature Engineering Process and Derived Attributes

Raw Attribute	Derived Feature
---------------	-----------------


date	year
date	month
date	month_name
status	status_group
quantity + amount	revenue
promotion_code	has_promotion

2.4 Spark SQL Analytics Framework

Spark SQL digunakan untuk melakukan analisis data pada dataset penjualan Amazon. Beberapa analisis yang dilakukan meliputi identifikasi kategori produk terlaris, distribusi status pesanan, tren penjualan bulanan, pengaruh promosi terhadap transaksi, performa saluran penjualan, serta analisis geografis berdasarkan wilayah penjualan. Selain itu, dilakukan juga analisis terhadap segmentasi harga produk dan status pengiriman untuk melihat pola transaksi yang terjadi. Query Spark SQL digunakan untuk membantu proses eksplorasi data dan menghasilkan informasi yang dapat digunakan dalam evaluasi performa penjualan.

2.5 Dual-Database Architecture and Data Integration

Penyimpanan data pada penelitian ini menggunakan dua jenis database, yaitu MySQL dan MongoDB. MySQL digunakan sebagai database relasional untuk menyimpan data transaksi dalam bentuk tabel terstruktur, sedangkan MongoDB digunakan untuk menyimpan data berbasis dokumen dengan struktur yang lebih fleksibel[6]. Data hasil pengolahan disimpan ke beberapa tabel dan koleksi sesuai kebutuhan analisis, seperti data transaksi utama, ringkasan penjualan bulanan, dan statistik kategori produk. Proses integrasi data dilakukan menggunakan JDBC untuk koneksi MySQL dan PyMongo untuk koneksi MongoDB. Penggunaan dua jenis database ini bertujuan untuk mendukung penyimpanan data yang lebih fleksibel serta memudahkan proses analisis data pada sistem big data[7].



Gambar 3. Dual Database Architecture

2.6 Performance evaluation and validation

Evaluasi pipeline dilakukan untuk melihat kualitas data hasil pengolahan dan konsistensi data pada sistem penyimpanan yang digunakan. Beberapa aspek yang dievaluasi meliputi kualitas data setelah proses pembersihan, jumlah data yang berhasil diproses, serta hasil analisis yang diperoleh dari dataset. Setelah tahap praproses, jumlah data berkurang dari 128.975 menjadi 113.004 data bersih akibat penghapusan data yang tidak valid dan duplikat. Selain itu, dilakukan analisis terhadap tingkat pengiriman pesanan, nilai rata-rata transaksi, dan distribusi penjualan berdasarkan kategori produk. Validasi data juga dilakukan dengan membandingkan hasil penyimpanan data pada MySQL dan MongoDB untuk memastikan data tersimpan dengan baik pada kedua sistem database[8].

3. Result and Discussion

3.1 Data Cleaning Results

Tahap praproses data berhasil meningkatkan kualitas dataset sebelum dilakukan analisis lebih lanjut. Dataset awal yang berjumlah 128.975 data transaksi berkurang menjadi 113.004 data bersih setelah proses penghapusan data tidak valid dan duplikat. Penanganan missing value dilakukan pada beberapa atribut seperti

courier_status, amount, currency, dan informasi lokasi pengiriman. Selain itu, proses penghapusan data duplikat berhasil menghilangkan 862 data order_id yang terdeteksi berulang. Setelah proses pembersihan selesai, dataset tidak lagi memiliki nilai kosong pada atribut penting sehingga data dapat digunakan untuk proses analisis dan pengolahan lebih lanjut secara lebih konsisten.

3.2 Key Performance Indicators (KPIs)

Analisis 113.004 catatan bersih mengungkapkan metrik kinerja utama: Total Pesanan mencapai 113.004 transaksi diproses selama periode 4 bulan. Total Pendapatan akumulatif adalah Rp 70.97 Juta INR di seluruh kategori produk. Tingkat Kesuksesan Pengiriman mencapai 90,4% (102.202 order dikirim), menunjukkan keunggulan operasional dalam pemenuhan pesanan. Nilai Order Rata-rata sebesar Rp 627,49 per transaksi menunjukkan ekonomi pelanggan yang sehat. Tingkat Pembatalan adalah 8,8% (9.956 order dibatalkan), relatif rendah dan dapat diterima untuk industri e-commerce. Cakupan Promosi mencapai 64% pesanan (72.469) termasuk kode promosi, menunjukkan engagement marketing yang tinggi. Metrik-metrik ini menunjukkan operasi bisnis yang sehat dengan tingkat konversi tinggi dan engagement pelanggan yang kuat[9].

3.3 Product Category Performance Analysis

Analisis terhadap 9 kategori produk menunjukkan adanya konsentrasi penjualan pada beberapa kategori utama. Kategori Set menjadi kategori dengan jumlah transaksi tertinggi, yaitu 44.123 pesanan dengan kontribusi pendapatan sekitar 39% dari total penjualan. Selain memiliki jumlah transaksi yang tinggi, kategori ini juga memiliki rata-rata harga produk yang lebih tinggi dibanding beberapa kategori lainnya. Kategori Kurta berada pada posisi kedua dengan 42.957 pesanan dan kontribusi pendapatan sebesar 27%, sedangkan kategori Western Dress menempati posisi ketiga dengan 13.951 pesanan dan kontribusi pendapatan sebesar 14%. Sementara itu, kategori Top menyumbang sekitar 8,6% pendapatan dan kategori lainnya memiliki kontribusi yang relatif lebih kecil. Hasil analisis menunjukkan bahwa kategori Set menjadi produk yang paling diminati pelanggan sehingga dapat menjadi pertimbangan dalam penentuan strategi stok dan promosi pada platform e-commerce.

Dominasi kategori Set menunjukkan bahwa pelanggan cenderung memilih produk pakaian yang telah dikombinasikan dalam satu paket dibandingkan produk fashion individual. Kondisi ini mengindikasikan bahwa konsumen pada platform e-commerce lebih mempertimbangkan aspek kepraktisan dan variasi produk dalam satu pembelian. Selain itu, tingginya kontribusi kategori Set terhadap total pendapatan menunjukkan bahwa kategori tersebut memiliki potensi besar untuk dijadikan fokus strategi promosi dan pengelolaan stok pada platform penjualan online.

3.4 Temporal Trends and Seasonal Patterns

Analisis penjualan bulanan menunjukkan adanya perubahan jumlah transaksi selama periode Maret hingga Juni 2022[10]. Bulan April mencatat jumlah transaksi tertinggi dengan 39.071 pesanan dan total pendapatan sebesar Rp 24,7 juta, meningkat dibandingkan bulan Maret yang hanya memiliki 140 pesanan. Pada bulan Mei, jumlah transaksi menurun menjadi 33.680 pesanan dengan pendapatan Rp 22,5 juta, kemudian kembali menurun pada bulan Juni menjadi 29.311 pesanan dengan pendapatan Rp 19,6 juta. Peningkatan transaksi pada bulan April kemungkinan dipengaruhi oleh tingginya aktivitas pembelian atau adanya periode promosi tertentu. Sementara itu, penurunan transaksi pada bulan berikutnya menunjukkan adanya pola musiman dalam aktivitas penjualan e-commerce yang dapat digunakan sebagai bahan evaluasi strategi bisnis dan pemasaran.

Penurunan jumlah transaksi pada bulan Mei dan Juni menunjukkan adanya pola musiman pada aktivitas pembelian pelanggan di platform e-commerce. Kondisi ini mengindikasikan bahwa volume transaksi dipengaruhi oleh periode promosi, tren pasar, serta perubahan perilaku konsumen pada waktu tertentu. Lonjakan transaksi pada bulan April juga dapat menjadi indikasi adanya peningkatan aktivitas belanja pada periode promosi atau seasonal event yang berdampak langsung terhadap peningkatan pendapatan perusahaan.

3.5 Geographic Market Analysis

Analisis geografis terhadap data penjualan di 46 wilayah India menunjukkan adanya konsentrasi transaksi pada beberapa wilayah tertentu. Kondisi ini sejalan dengan penelitian mengenai analisis geografis pada e-commerce yang menunjukkan bahwa distribusi penjualan umumnya terpusat pada wilayah tertentu. Maharashtra menjadi wilayah dengan jumlah pesanan tertinggi, yaitu 17.856 pesanan dengan kontribusi pendapatan sekitar 17% dari total penjualan. Posisi berikutnya ditempati oleh Karnataka dengan 13.968 pesanan dan Uttar Pradesh

dengan 8.462 pesanan. Hasil analisis menunjukkan bahwa 15 wilayah teratas menyumbang sekitar 89,2% dari total penjualan, sedangkan wilayah lainnya memiliki kontribusi yang relatif lebih kecil. Konsentrasi penjualan pada beberapa wilayah utama menunjukkan bahwa pasar e-commerce masih terpusat pada daerah dengan tingkat urbanisasi dan aktivitas ekonomi yang tinggi. Wilayah dengan kontribusi penjualan rendah dapat menjadi peluang pengembangan pasar melalui strategi promosi yang lebih spesifik sesuai karakteristik wilayah masing-masing[11]. Kondisi ini menunjukkan bahwa distribusi penjualan masih terpusat pada beberapa wilayah utama. Selain itu, wilayah dengan tingkat penjualan yang rendah dapat menjadi peluang untuk pengembangan pasar dan perluasan strategi pemasaran pada platform e-commerce.

3.6 Integration Validation

Proses integrasi data antara PySpark, MySQL, dan MongoDB berhasil dilakukan pada seluruh tahapan pipeline. Data hasil pengolahan dapat disimpan dan diakses kembali pada kedua sistem basis data tanpa kehilangan informasi penting. Validasi dilakukan dengan membandingkan jumlah data, hasil query, serta beberapa atribut utama pada MySQL dan MongoDB untuk memastikan konsistensi data setelah proses penyimpanan. Hasil validasi menunjukkan bahwa seluruh data transaksi, ringkasan penjualan bulanan, dan statistik kategori produk berhasil tersimpan sesuai struktur masing-masing basis data. Integrasi menggunakan JDBC untuk MySQL dan PyMongo untuk MongoDB juga berjalan dengan stabil selama proses pengujian. Penggunaan kombinasi basis data relasional dan NoSQL memungkinkan pengelolaan data dilakukan secara lebih fleksibel sesuai karakteristik data pada lingkungan big data[12].


3.7 Dashboard Visualisasi Hasil Analisis

Hasil akhir dari pipeline data disajikan dalam sebuah dashboard interaktif yang dibangun dengan Streamlit. Dashboard ini terhubung langsung ke data bersih yang telah disimpan di MySQL dan MongoDB, sehingga seluruh visualisasi dan metrik yang ditampilkan bersumber dari data hasil pemrosesan.

3.7.1 Tampilan Dashboard dan Indikator Kerja

Gambar 4 memperlihatkan tampilan awal dashboard bagian atas. Pada sisi kiri terdapat sidebar yang memuat informasi teknologi yang digunakan (PySpark, MySQL, MongoDB, Streamlit) serta tombol untuk menyegarkan data secara manual atau otomatis setiap 30 detik. Di bagian tengah dan kanan ditampilkan empat kartu indikator kinerja utama (KPI). Total pesanan tercatat sebanyak 113.004 transaksi, total pendapatan mencapai Rp70,97 juta (setara £7,10 Cr), rata-rata nilai pesanan adalah Rp628, dan kategori produk Set menjadi penyumbang pendapatan tertinggi.

Pada bagian bawah tersedia grafik garis tren pendapatan per bulan. Terlihat bahwa pendapatan tertinggi terjadi pada April 2022, kemudian menurun secara bertahap hingga Juni 2022. Grafik ini dapat diubah parameternya oleh pengguna untuk menampilkan metrik lain seperti jumlah pesanan atau kuantitas barang.




Gambar 4. Tampilan Dashboard dan Indikator Kerja

3.7.2 Performa Tren Penjualan

3.7.2.1 Tren Penjualan Bulanan


Gambar 1 menampilkan analisis tren penjualan bulanan. Pada bagian atas terdapat pilihan tahun (dalam kasus ini hanya 2022) dan menu untuk memilih metrik yang ingin ditampilkan, misalnya pendapatan, jumlah pesanan, atau kuantitas barang. Grafik garis dengan area fill menyajikan pendapatan dalam INR per bulan selama periode Maret hingga Juni 2022. Sumbu vertikal menunjukkan besaran pendapatan (dalam jutaan), sementara sumbu horizontal menampilkan bulan. Dari grafik terlihat bahwa pendapatan tertinggi terjadi pada April 2022, kemudian menurun pada Mei dan Juni. Pola ini mengindikasikan adanya lonjakan penjualan di bulan April yang kemungkinan berkaitan dengan promosi atau musim belanja tertentu. Pengguna dapat mengganti metrik untuk melihat jumlah pesanan atau kuantitas barang melalui menu yang tersedia.



Gambar 5. Tren Penjualan Bulanan

3.7.2.2 Pertumbuhan Bulanan

Gambar 2 menyajikan diagram batang yang menggambarkan persentase perubahan pendapatan antar bulan (month-over-month). Sumbu vertikal menunjukkan nilai persentase perubahan, sedangkan sumbu horizontal menampilkan bulan April, Mei, dan Juni 2022. Lonjakan yang sangat tinggi (+27.628,6%) terlihat pada bulan April. Hal ini disebabkan karena bulan Maret (bulan pertama dalam dataset) hanya mencatat 140 pesanan sehingga peningkatan ke April menjadi ekstrem. Pada bulan Mei dan Juni, pertumbuhan menunjukkan angka negatif masing-masing -8,8% dan -13,0%. Diagram ini membantu mengidentifikasi bahwa setelah lonjakan awal, aktivitas penjualan cenderung menurun secara bertahap. Angka negatif tersebut dapat menjadi masukan untuk mengevaluasi strategi promosi atau pengelolaan stok pada periode setelah puncak penjualan.




Gambar 5. Pertumbuhan Bulanan

3.7.3 Performa Kategori Produk

3.7.3.1 Distribusi Pendapatan dan Jumlah Pesanan

Gambar 6 menampilkan dua diagram yang menggambarkan kontribusi masing-masing kategori. Diagram batang horizontal di sebelah kiri menunjukkan total pendapatan per kategori dalam jutaan rupiah. Kategori Set menempati posisi pertama dengan pendapatan Rp35,5 juta, disusul kurta (Rp19,0 juta) dan Western Dress (Rp10,1 juta). Keempat kategori lainnya (Top, Ethnic Dress, Blouse, Bottom, Saree, Dupatta) memberikan kontribusi yang relatif kecil. Diagram lingkaran di sebelah kanan memperlihatkan proporsi jumlah pesanan. Kategori Set menyumbang 39% dari total pesanan, kurta 38%, Western Dress 12,3%, dan sisanya (sekitar 10,5%) tersebar di enam kategori lainnya. Kedua grafik ini mempertegas bahwa aktivitas penjualan sangat terkonsentrasi pada tiga kategori utama, terutama Set dan kurta.




Gambar 6. Chart Distribusi Pendapatan dan Jumlah Pesanan

3.7.3.2 Peta Pendapatan per Kategori terhadap Bulan

Gambar 7 menyajikan heatmap yang memetakan pendapatan (dalam juta rupiah) untuk setiap kategori pada bulan April, Mei, dan Juni 2022. Warna hijau yang lebih pekat menandakan pendapatan yang lebih besar.

Dari peta panas ini terlihat bahwa kategori Set mendominasi pendapatan pada bulan April (Rp13,3 juta) dan Mei (Rp10,9 juta), sementara kategori kurta memberikan kontribusi Rp6,7 juta (April) dan Rp5,7 juta (Mei). Kategori Western Dress juga mencatat angka Rp2,6–3,8 juta pada periode yang sama. Bulan Juni secara umum menunjukkan pendapatan yang lebih rendah dibandingkan April dan Mei untuk hampir semua kategori. Hasil ini memperkuat temuan bahwa lonjakan penjualan pada bulan April didorong terutama oleh kategori Set dan kurta.



Gambar 7. Heatmap Pendapatan per Kategori

3.7.3.3 Tabel Statistik per Kategori

Gambar 8 menyajikan tabel yang merangkum enam metrik untuk setiap kategori: total pesanan, total kuantitas barang terjual, total pendapatan, harga rata-rata, harga maksimum, dan harga minimum. Kategori Set mencatat total pesanan 44.123, total pendapatan Rp35,5 juta, harga rata-rata Rp833, dan harga maksimum Rp5.495. Kategori kurta memiliki 42.957 pesanan dengan pendapatan Rp19,0 juta serta harga rata-rata Rp456. Kategori Western Dress mencatat 13.951 pesanan, pendapatan Rp10,1 juta, harga rata-rata Rp762. Tabel ini memudahkan perbandingan secara rinci, sekaligus menunjukkan rentang harga yang lebar pada kategori Set (hingga Rp5.495) dibandingkan kategori lain.


	Category	Total Orders	Total Qty Sold	Total Revenue	Avg Price	Max Price	Min Price
0	Set	44,123	42,433	₹35,516,449	₹833	5,495	0
1	kurta	42,957	41,358	₹19,016,764	₹456	2,796	0
2	Western Dress	13,951	13,220	₹10,137,591	₹762	2,860	0
3	Top	9,585	9,333	₹4,928,500	₹525	1,764	0
4	Ethnic Dress	1,020	982	₹706,521	₹719	1,449	0
5	Blouse	846	811	₹425,041	₹522	1,266.66	0
6	Bottom	387	367	₹131,704	₹356	729	0

Gambar 8. Tabel Detail Statistik Kategori

3.7.4 Distribusi Geografis

3.7.4.1 Negara Bagian dengan Order dan Pendapatan Tertinggi

Gambar 9 menampilkan dua diagram batang horizontal yang menyajikan sepuluh negara bagian dengan jumlah pesanan terbanyak (kiri) dan pendapatan tertinggi (kanan). Pada diagram kiri, Maharashtra menempati urutan pertama dengan 17.856 pesanan, diikuti Karnataka (13.968 pesanan) dan Tamil Nadu (9.007 pesanan). Diagram kanan menunjukkan bahwa Maharashtra juga memimpin dalam hal pendapatan (sekitar Rp11,4 juta), disusul Karnataka (Rp9,0 juta) dan Uttar Pradesh (Rp5,8 juta). Urutan lima besar pada kedua diagram relatif sama, meskipun posisi Telangana dan Uttar Pradesh berbeda tipis. Secara keseluruhan, 10 negara bagian teratas menyumbang lebih dari 85% total pesanan dan pendapatan, mengindikasikan adanya konsentrasi pasar yang kuat di wilayah-wilayah tertentu.



Gambar 9. Hubungan Jumlah Order dan Pendapatan per Negara Bagian

3.7.4.2 Hubungan Antara Jumlah Order dan Pendapatan per Negara Bagian

Gambar 10 menyajikan diagram gelembung (bubble chart) yang memetakan setiap negara bagian berdasarkan dua sumbu: sumbu horizontal menunjukkan jumlah pesanan, sumbu vertikal menunjukkan total pendapatan. Ukuran gelembung sebanding dengan jumlah pesanan (semakin besar gelembung, semakin banyak order). Dari diagram ini terlihat bahwa Maharashtra berada di pojok kanan atas (order tinggi, pendapatan tinggi), diikuti Karnataka dan Tamil Nadu. Beberapa wilayah seperti Delhi dan Haryana memiliki jumlah pesanan sedang tetapi pendapatan yang relatif lebih rendah dibandingkan Maharashtra. Diagram ini memudahkan identifikasi wilayah dengan performa terbaik (kuadran kanan atas) dan wilayah yang berpotensi untuk ditingkatkan (misalnya yang memiliki order tinggi namun pendapatan rendah). Secara kuantitatif, 15 wilayah teratas menyumbang 89,2% dari total penjualan.



Gambar 10. Hubungan Jumlah Order dan Pendapatan per Negara Bagian


3.7.5 Segmentasi Order dan Harga

3.7.5.1 Distribusi Status Order dan Tipe Pelanggan

Gambar 11 menampilkan dua diagram lingkaran. Diagram sebelah kiri menunjukkan proporsi status pesanan. Sebanyak 90,4% pesanan berstatus Shipped (telah dikirim), 8,81% Cancelled (dibatalkan), 0,517% Pending, dan 0,232% Other. Tingkat pengiriman yang tinggi (di atas 90%) menandakan operasional pemenuhan pesanan berjalan baik, sementara angka pembatalan yang relatif rendah (kurang dari 9%) masih dalam batas wajar untuk industri e-commerce. Diagram sebelah kanan membandingkan tipe pelanggan B2B dan B2C. Transaksi B2C mendominasi dengan porsi 99,3% (112.235 pesanan), sedangkan B2B hanya 0,681% (769 pesanan). Hal ini menunjukkan bahwa platform Amazon yang diteliti lebih berorientasi pada konsumen individu.

dibandingkan bisnis antar perusahaan.

Tingginya persentase status shipped menunjukkan bahwa proses pemenuhan pesanan berjalan dengan baik dan relatif stabil. Sementara itu, tingkat pembatalan yang masih berada di bawah 10% menunjukkan bahwa kualitas layanan dan proses transaksi pada platform e-commerce masih berada pada kondisi yang cukup baik untuk menjaga kepuasan pelanggan.




Gambar 11. Distribusi Status Order dan Tipe Pelanggan

3.7.5.2 Segmentasi Harga per Kategori

Gambar 12 menyajikan dua diagram batang untuk menganalisis segmentasi harga pada setiap kategori produk. Produk dikelompokkan menjadi tiga segmen berdasarkan harga satuan: *Budget* (<300 INR), *Mid-Range* (300-700 INR), dan *Premium* (>700 INR). Diagram batang kiri (*grouped bar chart*) menunjukkan jumlah pesanan per segmen untuk kategori yang dipilih (pengguna dapat memfilter kategori melalui menu). Diagram batang kanan (*stacked bar chart*) menampilkan total pendapatan dari setiap segmen secara bertumpuk. Untuk kategori *Blouse*, segmen *Mid-Range* mendominasi baik dari sisi jumlah pesanan maupun pendapatan. Kategori *Bottom* juga didominasi segmen *Mid-Range*, sementara kategori *Ethnic Dress* dan *Saree* cenderung lebih banyak di segmen *Premium*. Visualisasi ini membantu memahami posisi harga masing-masing kategori di pasar.


Dominasi segmen Mid Range pada beberapa kategori menunjukkan bahwa mayoritas pelanggan cenderung memilih produk dengan harga menengah yang dianggap lebih seimbang antara kualitas dan harga. Temuan ini dapat menjadi dasar dalam menentukan strategi penetapan harga dan pengelompokan produk pada platform e-commerce.



Gambar 12. Segmentasi Harga per Kategori

3.7.5.3 Rata-Rata Harga per Segmen

Gambar 13 menampilkan diagram batang yang membandingkan rata-rata harga antar ketiga segmen. Segmen Budget memiliki rata-rata harga Rp92, segmen Mid-Range Rp459, dan segmen Premium Rp833. Perbedaan yang jelas antara ketiga segmen menunjukkan bahwa pengelompokan berdasarkan batasan 300 INR dan 700 INR cukup efektif untuk membedakan tingkat harga. Informasi ini berguna untuk menyusun strategi penetapan harga pada setiap kategori serta mengevaluasi apakah suatu produk termasuk dalam rentang harga yang sesuai dengan segmen pasarnya.




Gambar 13. Rata-Rata Harga per Segmen

3.7.6 Rincian Teknis Pipeline

3.7.6.1 Diagram Alur Pipeline


Gambar 14 menampilkan diagram alir (pipeline flow) dalam bentuk teks yang menggambarkan seluruh tahapan pemrosesan data. Alur dimulai dari file CSV, kemudian dilanjutkan dengan proses ingest dan penentuan schema menggunakan PySpark, dilanjutkan dengan pembersihan data (10 langkah) hingga menghasilkan dataframe bersih (df_clean). Dari df_clean dilakukan agregasi untuk menghasilkan empat dataframe ringkasan (df_by_category, df_monthly, df_status, df_top_states). Selain itu, df_clean juga diproses melalui delapan query Spark SQL untuk menghasilkan berbagai hasil analitik. Selanjutnya, df_clean disimpan ke MySQL (tabel orders, monthly_summary, category_stats) dan MongoDB (koleksi orders_detail, category_insights). Terakhir, data dari kedua basis diintegrasikan melalui cross join dan divisualisasikan ke dalam dashboard Streamlit. Diagram ini memudahkan pembaca memahami keseluruhan arsitektur pipeline secara sekilas.



Gambar 14. Diagram Alur Pipeline

3.7.6.2 Skema Basis Data

Gambar 15 menyajikan skema dari kedua basis data yang digunakan. Pada sisi kiri, MySQL dengan nama basis data `amazon_sales_db` memiliki tiga tabel: `orders` (26 kolom), `monthly_summary` (8 kolom), dan `category_stats` (8 kolom). Pada sisi kanan, MongoDB dengan nama basis data `amazon_sales` memiliki dua koleksi: `orders_detail` (menyimpan data transaksi lengkap) dan `category_insights` (menyimpan statistik kategori). Skema ini menunjukkan bahwa data terstruktur disimpan di MySQL, sementara data semi-terstruktur (misalnya `promotion_ids` dalam bentuk array dan `price_range` sebagai objek) disimpan di MongoDB.



Gambar 15. Skema Basis Data

3.7.6.3 Daftar Query Spark SQL

Gambar 16 mendaftarkan sembilan query Spark SQL yang digunakan selama proses analisis. Setiap query disertai dengan deskripsi singkat mengenai fungsi dan klausa SQL yang digunakan. Query tersebut meliputi: (Q1) kombinasi kategori dan ukuran terbaik, (Q2) funnel konversi order per status, (Q3) sepuluh hari dengan pendapatan tertinggi, (Q4) dampak promosi terhadap penjualan, (Q5) performa saluran penjualan dan metode pemenuhan, (Q6) pertumbuhan pendapatan bulan-ke-bulan menggunakan fungsi jendela LAG, (Q7) pangsa pendapatan dan peringkat per negara bagian, (Q8) segmentasi harga berdasarkan anggaran/menengah/premium, dan (Q9) analisis dampak status kurir. Daftar ini menunjukkan variasi analisis yang dapat dilakukan dengan Spark SQL pada dataset e-commerce.

9 SPARK SQL QUERIES PIPELINE	
Q1	Top Kombinasi Kategori & Ukuran GROUP BY category, size ORDER BY revenue DESC
Q2	Funnel Konversi Order per Status COUNT, SUM, AVG, WINDOW OVER() pct_orders
Q3	Top 10 Hari Revenue Tertinggi GROUP BY date ORDER BY daily_revenue DESC
Q4	Dampak Promosi terhadap Penjualan CASE WHEN has_promotion AVG qty & revenue
Q5	Performa Sales Channel & Fulfillment GROUP BY sales_channel, fulfillment pct_of_total
Q6	Month-over-Month Revenue Growth WITH CTE LAG() WINDOW FUNCTION mom_growth_pct
Q7	State Performance – Revenue Share RANK() OVER pct_orders, pct_revenue
Q8	Segmentasi Harga Budget/Mid/Premium CASE WHEN amount < 368/700 GROUP BY segment
Q9	Courier Status Impact Analysis GROUP BY courier_status, status_group states_covered

Gambar 16. Daftar Query Spark SQL

4. Conclusion

Penelitian ini berhasil membangun pipeline analitik big data berbasis Apache Spark untuk pengolahan data transaksi e-commerce Amazon secara terintegrasi. Proses preprocessing dan feature engineering mampu meningkatkan kualitas data sebelum dilakukan analisis menggunakan Spark SQL. Integrasi MySQL dan MongoDB memberikan fleksibilitas dalam penyimpanan data terstruktur maupun semi-terstruktur. Hasil penelitian menunjukkan bahwa pendekatan distributed analytics mampu mendukung proses analisis penjualan secara efisien pada dataset transaksi berskala besar. Penelitian selanjutnya dapat dikembangkan dengan penerapan machine learning, streaming analytics, serta dashboard business intelligence real-time.

Acknowledgments

Penelitian ini didukung oleh Departemen Teknologi Informasi Institut Teknologi Del dan dikembangkan dengan teknologi sumber terbuka PySpark, MySQL, dan MongoDB. Dataset Penjualan Amazon bersumber dari Kaggle. Apresiasi khusus kepada para penasihat fakultas dan tim teknis atas dukungan selama pengembangan dan validasi pipeline.

References

- [1] J. Dean and S. Ghemawat, "MapReduce : Simplified Data Processing on Large Clusters," vol. 51, no. 1, pp. 107–113, 2008.
- [2] B. Y. M. Zaharia *et al.*, "Apache Spark : A Unified Engine for Big Data Processing".
- [3] M. I. Gifari, "Amazon Sale Report," Kaggle. Accessed: May 20, 2026. [Online]. Available: <https://www.kaggle.com/datasets/muhammadihamgifari/amazon-sale-report>
- [4] S. García, J. Luengo, and F. Herrera, *Data Preprocessing in Data Mining*.
- [5] A. Zheng and A. Casari, *Feature Engineering for Machine Learning*.
- [6] C. A. Gy and D. R. Zmaranda, "A Comparative Study of MongoDB and Document-Based MySQL for Big Data Application Data Management," 2022.
- [7] H. Abbes and F. Gargouri, "Big Data Integration : a MongoDB Database and Modular Ontologies based Approach," *Procedia - Procedia Comput. Sci.*, vol. 96, no. September, pp. 446–455, 2016, doi: 10.1016/j.procs.2016.08.099.
- [8] Á. Vathy-fogarassy and T. Húgyák, "Uniform data access platform for SQL and NoSQL database systems," vol. 69, pp. 93–105, 2017, doi: 10.1016/j.is.2017.04.002.
- [9] M. A. Waller and S. E. Fawcett, "Data Science , Predictive Analytics , and Big Data : A Revolution That Will Transform Supply Chain Design and Management," vol. 34, no. 2, pp. 77–84, 2013, doi: 10.1111/jbl.12010.
- [10] C. K. Murni, A. F. Choiri, and F. D. Rahmawati, "Product Demand Forecasting in E-Commerce with Big Data Analytics : Personalization , Decision Making and Optimization," vol. d, no. April, pp. 1–6, 2025.

- [11] A. Gandomi and M. Haider, “Beyond the hype: Big data concepts, methods, and analytics,” *Int. J. Inf. Manage.*, vol. 35, no. 2, pp. 137–144, 2015, doi: 10.1016/j.ijinfomgt.2014.10.007.
- [12] R. Cattell, “Scalable SQL and NoSQL Data Stores,” no. December, 2011.